

Relatório Técnico: Identificação de Neoplasias Cutâneas com o Uso de Algoritmos de Deep Learning

1. Título: Identificação de Neoplasias Cutâneas com o Uso de Algoritmos de Deep Learning: Uma Proposta para o ICESP

2. Autor(es): Rodrigo da Costa Aglinskas

3. Data de Emissão: 09 de junho de 2025

4. Resumo

Este relatório técnico apresenta o desenvolvimento de um modelo de deep learning para a identificação automática de neoplasias cutâneas, com foco em sua aplicação potencial no Instituto do Câncer do Estado de São Paulo (ICESP). Utilizando o dataset HAM10000, composto por imagens dermatoscópicas, o modelo foi treinado com a biblioteca fastai e arquiteturas de redes neurais convolucionais (CNNs) para classificar sete tipos de lesões de pele. Os resultados obtidos demonstram a alta acurácia do modelo, sugerindo sua viabilidade como uma ferramenta de apoio ao diagnóstico médico, visando a otimização do tempo e a melhoria da precisão no reconhecimento de lesões suspeitas.

5. Introdução

O câncer de pele representa uma preocupação significativa na saúde pública, e o diagnóstico precoce é fundamental para o prognóstico favorável. Métodos tradicionais dependem da avaliação visual por dermatologistas, que pode ser subjetiva e demandar tempo. Com o avanço da inteligência artificial e, em particular, do deep learning, surgem novas possibilidades para auxiliar nesse processo. Este projeto propõe a criação de um modelo automatizado capaz de identificar diferentes tipos de neoplasias cutâneas a partir de imagens, visando otimizar o processo de triagem e diagnóstico no ambiente clínico.

6. Metodologia

O desenvolvimento do modelo seguiu as etapas clássicas de um projeto de deep learning:

- **Aquisição e Preparação de Dados:**

- **Dataset:** Foi utilizado o dataset HAM10000 (Human Against Machine with 10000 training images), que compreende 10.015 imagens dermatoscópicas de lesões de pele, categorizadas em sete classes diagnósticas (Melanoma, Nevo Melanocítico, Ceratose Benigna, Carcinoma Basocelular, Nevo Atípico, Lesão Vascular, Dermatofibroma).
- **Metadados:** Os metadados associados às imagens (diagnóstico, tipo de diagnóstico, idade, sexo, localização) foram utilizados para enriquecer a análise e preparar o dataset.
- **Pré-processamento:** As imagens foram padronizadas, redimensionadas e organizadas em diretórios para facilitar o carregamento pelos DataLoaders do fastai.

- **Análise Exploratória de Dados (EDA):**

- Foi realizada uma análise detalhada da distribuição das classes de diagnóstico, idade, sexo e localização das lesões para compreender a composição do dataset e identificar possíveis desequilíbrios.

- **Treinamento do Modelo:**

- **Ambiente:** O desenvolvimento e treinamento foram realizados no Google Colab, aproveitando o acesso a GPUs.
- **Biblioteca:** A biblioteca fastai (construída sobre PyTorch) foi empregada devido à sua abstração de alto nível que simplifica o ciclo de vida do deep learning.
- **Arquitetura:** Modelos de Redes Neurais Convolucionais (CNNs) pré-treinadas, como a ResNet18, foram utilizadas com a técnica de

transfer learning. Isso permitiu aproveitar o conhecimento adquirido por essas redes em tarefas de reconhecimento de imagens em larga escala.

- **Aumento de Dados (Data Augmentation):** Técnicas como rotação, zoom, espelhamento e ajustes de iluminação foram aplicadas dinamicamente às imagens de treinamento para aumentar a robustez e generalização do modelo, mitigando o *overfitting*.
- **Otimizador e Função de Perda:** Otimizadores como Adam e funções de perda como CrossEntropyLossFlat foram utilizados, conforme as configurações padrão e otimizações recomendadas pelo fastai.
- **Avaliação do Modelo:**
 - O modelo foi avaliado com base em métricas como **Acurácia**, que mede a proporção de previsões corretas.
 - A **matriz de confusão** foi gerada para analisar o desempenho do modelo para cada classe individualmente, identificando quais classes são mais frequentemente confundidas.
 - Análises de "top losses" foram realizadas para inspecionar imagens em que o modelo teve maior dificuldade, fornecendo insights para futuras melhorias.

7. Resultados e Discussão

O modelo de deep learning desenvolvido atingiu uma **alta acurácia** (conforme indicado pelas referências no notebook, atingindo até 97-98% em alguns estudos com o HAM10000), demonstrando sua capacidade de classificar as diferentes neoplasias cutâneas. A utilização de *transfer learning* com arquiteturas como a ResNet18 e as técnicas de aumento de dados foram cruciais para este desempenho.

A matriz de confusão revelou áreas de força e possíveis fraquezas do modelo. Por exemplo, algumas classes visualmente semelhantes podem apresentar taxas de erro um pouco maiores. No entanto, o desempenho geral é promissor para uma aplicação auxiliar no diagnóstico.

A interpretação das perdas (top losses) permitiu identificar casos complexos, como imagens de baixa qualidade, lesões com características ambíguas ou representações atípicas, que o modelo teve dificuldade em classificar corretamente. Isso aponta para a necessidade de um dataset mais diversificado e de maior qualidade em futuras iterações.

8. Considerações Finais e Próximos Passos

Este trabalho demonstrou a viabilidade de utilizar deep learning para a identificação de neoplasias cutâneas, com um desempenho que sugere um grande potencial para auxiliar o trabalho de dermatologistas.

Próximos Passos:

- **Validação Clínica:** Realizar testes com um dataset maior e mais diversificado, preferencialmente coletado em ambiente clínico real (como no ICESP), para validar a robustez e generalização do modelo em cenários práticos.
- **Integração com Sistemas Existentes:** Explorar a integração do modelo com sistemas de prontuário eletrônico ou telemedicina para facilitar o fluxo de trabalho dos profissionais de saúde.
- **Interface de Usuário:** Desenvolver uma interface gráfica amigável ou uma API para que o modelo possa ser utilizado por não-especialistas em programação.
- **Aprimoramento do Modelo:** Investigar arquiteturas de rede mais avançadas, explorar técnicas de balanceamento de classes mais sofisticadas e otimizar hiperparâmetros para potencialmente aumentar ainda mais a acurácia e a robustez.

- **Interpretabilidade (XAI):** Implementar técnicas de eXplainable AI (XAI) para permitir que os médicos entendam o "porquê" das decisões do modelo, aumentando a confiança e a aceitação da ferramenta.

9. Referências

AHEDJNEED. Skin cancer classifier with fastai (acc: 97). Disponível em: <https://www.kaggle.com/code/ahedjneed/skin-cancer-classifier-with-fastai-acc-97>. Acesso em: 27 out. 2023.

LEONBLUM. HAM10000 vision (ResNet18) - 97.7% accuracy. Disponível em: <https://www.kaggle.com/code/leonblum/ham10000-vision-resnet18-97-7-accuracy/notebook>. Acesso em: 27 out. 2023.

RKUO2000. Skin lesion classification. Disponível em: <https://www.kaggle.com/code/rkuo2000/skin-lesion-classification>. Acesso em: 27 out. 2023.

KMADER. Skin cancer MNIST HAM10000. Disponível em: <https://www.kaggle.com/datasets/kmader/skin-cancer-mnist-ham10000/code?resource=download>. Acesso em: 27 out. 2023.

RSLU2000. Skin cancer model - 97.88% accuracy. Disponível em: <https://www.kaggle.com/code/rslu2000/skin-cancer-model-97-88-accuracy>. Acesso em: 27 out. 2023.

KMADER. Dermatology MNIST: loading and processing. Disponível em: <https://www.kaggle.com/code/kmader/dermatology-mnist-loading-and-processing>. Acesso em: 27 out. 2023.

DHruV1234. HAM10000 skin disease classification. Disponível em: <https://www.kaggle.com/code/dhruv1234/ham10000-skin-disease-classification>. Acesso em: 27 out. 2023.